

Protocolo Experimental

Componente Empírico – Sistema CarniCore

Enfoque 2: Detección automática de ambigüedad y malos olores
en los requisitos funcionales

Entrega 3 (2A): Especificación de Requisitos Completa + Componente Empírico

Asignatura: Ingeniería de Requerimientos [20303] – 4to Nivel

Estándares de referencia: ISO/IEC/IEEE 29148:2018 – ISO/IEC 25010:2023

Repositorio: https://github.com/EdhuXav/CarniCore_Proyecto_ISR401
Ubicación de este documento: 06_Experimento/protocolo.pdf
Organización cliente: Distribuidora Cárnicos Pucayacu (seudónimo declarado; aval institucional en 08_Etica/)
Categoría de riesgo ético: C – riesgo mínimo operativo
Docente supervisor: PhD. Guerrero Ulloa Gleiston Cicerón

Rol	Responsable	Responsabilidad en el estudio
Analista líder	Castro Bajaña Ariel Omar	Coordina el diseño experimental, registro OSF
Modelador	Gamarra Araujo Edhu Xavier	Implementación del detector, control de versiones
Documentador	Pérez Ruiz Carlos Andrés	Redacción del protocolo y del reporte de resultados
Verificador	Quintero Gende Erick Jahir	Diseño de la rúbrica experta, análisis de acuerdo inter-evaluador
Apoyo de campo	Crespo Espinoza Kleber Obed	Reclutamiento y consentimiento de personas expertas

Listado de autoría vigente para esta versión, consistente con la portada del ERS/SRS v3.0 y con la Adenda Ética de la Segunda Ronda.

Versión 1.0 – 02 de agosto de 2026 (semana 11, período académico 2026–2027 PPA), fecha de cierre de

esta versión. Registro previo en OSF confirmado el 02/08/2026 (<https://osf.io/wud69>), anterior a toda recolección de datos (Sección 13).

Historial de versiones

Versión	Fecha	Autor(es)	Descripción del cambio
1.0	02/08/2026	Equipo CarniCore	Primera versión completa del protocolo experimental del Enfoque 2, elaborada a partir de la Sección 7 del ERS/SRS v3.0 y de la Sección 3 de la Adenda Ética de la Segunda Ronda (08_Etica/Adenda_Segunda_Ronda.pdf).

Contents

1	Identificación del estudio y del equipo	2
2	Antecedentes y motivación	2
3	Pregunta de investigación (formato PICOC)	2
4	Hipótesis	2
5	Variables	3
6	Diseño del estudio	3
7	Población, muestra y criterios de selección	4
8	Instrumentos	5
8.1	Detector automático de ambigüedad y malos olores	5
8.2	Rúbrica de clasificación experta	5
8.3	Ficha de perfil de la persona experta	5
8.4	Consentimiento informado de personas expertas	6
9	Procedimiento	6
10	Plan de análisis estadístico	7
11	Consideraciones éticas	7
12	Amenazas a la validez (avance)	8
13	Cronograma de ejecución	8
	Referencias	9

1 Identificación del estudio y del equipo

Título del estudio. Detección automática de ambigüedad y malos olores en los requisitos funcionales del sistema CarniCore: un estudio comparado frente al juicio de personas expertas.

Sistema bajo estudio. CarniCore – Sistema de Trazabilidad, Pesaje Inteligente e Inventario para la Distribuidora Cárnicos Pucayacu (La Maña, Cotopaxi), tal como se especifica en el ERS/SRS v3.0 (01_ERS/ERS_SRS_2A_v1.0.pdf).

Relación con el ERS. Este protocolo desarrolla en detalle la Sección 7 (*Componente Empírico – Diseño del Estudio*) del ERS/SRS y opera bajo los límites de uso de inteligencia artificial declarados en la Sección 4 de la Adenda Ética de la Segunda Ronda. Ninguna afirmación de este documento sustituye o contradice lo declarado en el ERS; en caso de discrepancia futura, prevalece el ERS conforme a la regla de armonización de la guía de la Entrega 3 (2A).

Encuadre normativo. El diseño, la ejecución y el reporte de este estudio siguen las guías consensuadas de investigación empírica en ingeniería de software [5, 7], y el registro previo del protocolo sigue la práctica de preregistro documentada por Nosek et al. [6].

2 Antecedentes y motivación

El ERS/SRS de CarniCore documenta 25 requisitos funcionales (RF-01 a RF-25, Sección 3.2), de los cuales RF-01 a RF-16 provienen de la elicitación inicial (Entrega 1B) y RF-17 a RF-25 de la segunda ronda de campo de esta entrega. Como en todo proceso de elicitación basado en entrevistas y en la redacción manual de requisitos, existe el riesgo de que algunos enunciados contengan *malos olores* textuales – cuantificadores vagos (por ejemplo, “rápido”, “fácil de usar”), conjunciones que ocultan más de un requisito en un mismo enunciado, o construcciones en voz pasiva que oscurecen al responsable de la acción – patrones que la literatura asocia con ambigüedad y con dificultades posteriores de verificación [2, 3].

La revisión manual de ambigüedad por parte de personas expertas es el método de referencia (*gold standard*), pero es costosa en tiempo y no escala a conjuntos de requisitos grandes. Este estudio evalúa si un detector automático basado en patrones textuales puede aproximar ese juicio experto con una precisión aceptable, aplicado sobre el conjunto real y completo de RF de CarniCore. El estudio es una réplica pequeña, situada en un dominio real ecuatoriano de distribución cárnica, de la línea de investigación sobre detección automática de ambigüedad en requisitos [2, 3].

3 Pregunta de investigación (formato PICOC)

La pregunta de investigación se hereda sin modificaciones de la Sección 7.1 del ERS/SRS y de la Sección 3 de la Adenda Ética de la Segunda Ronda, para mantener trazabilidad completa entre ambos documentos.

RQ1. ¿Con qué precisión un detector automático replica el juicio de personas expertas al identificar RF ambiguos en el conjunto de requisitos de CarniCore?

4 Hipótesis

El estudio compara la clasificación binaria (ambiguo / no ambiguo) producida por el detector automático contra el consenso de personas expertas, tomado como referencia. La hipótesis se plantea sobre el nivel de acuerdo entre ambas fuentes, medido con el coeficiente κ de Cohen.

Población	Los 25 requisitos funcionales elicitados para CarniCore (RF-01 a RF-25, ERS Sección 3.2). Se trabaja con el censo completo, no con una muestra.
Intervención	Un detector automático de ambigüedad y malos olores (cuantificadores vagos, conjunciones múltiples, voz pasiva), implementado como script propio en Python mediante expresiones regulares por categoría (Sección 7 de este protocolo, <code>06_Experimento/scripts_analisis/detector_ambiguedad.py</code>).
Comparación	El juicio consensuado de al menos tres personas expertas (cinco recomendado por la guía de la Entrega 3) que clasifican cada RF como “ambiguo” o “no ambiguo” sin conocer la salida del detector.
Resultado	Precisión, exhaustividad (<i>recall</i>) y medida F1 del detector respecto al consenso experto; acuerdo inter-evaluador κ de Cohen [1] entre pares de expertos y κ de Fleiss [4] entre el conjunto de expertos.
Contexto	Proyecto académico de Ingeniería de Requerimientos aplicado a un dominio real de distribución cárnica en Ecuador (asignatura ISR-401/20303, UTEQ).

Table 2: Pregunta de investigación en formato PICOC.

H0 El acuerdo entre el detector automático y el consenso experto no supera el nivel esperable por azar ($\kappa \leq 0$); equivalentemente, la medida F1 del detector no difiere de la que produciría una clasificación aleatoria con la misma prevalencia de RF ambiguos observada en el consenso experto.

H1 El acuerdo entre el detector automático y el consenso experto es significativamente superior al nivel esperable por azar ($\kappa > 0$).

Estas hipótesis se evalúan de forma descriptiva e inferencial conforme al plan de análisis de la Sección 9. Dado el tamaño reducido de la población (25 RF), el estudio se reporta con énfasis en el tamaño del efecto (κ , precisión, *recall*, F1) y no únicamente en la significancia estadística, siguiendo la recomendación de Wohlin et al. [7] para estudios de tamaño muestral pequeño.

5 Variables

6 Diseño del estudio

Se trata de un estudio observacional de exactitud diagnóstica (*diagnostic accuracy study*), de diseño transversal y censal: se aplican dos procedimientos de clasificación (detector automático; consenso experto) sobre la misma población completa de 25 RF, sin asignación aleatoria ni manipulación de condiciones. La unidad de análisis es el requisito funcional individual (RF-01 a RF-25). No se realiza muestreo: se trabaja con el censo completo de RF vigente en el ERS al momento de la ejecución del experimento, consistente con la exigencia de un mínimo de 25 RF de la guía de la Entrega 3 (2A).

Cegamiento. Las personas expertas clasifican los RF sin conocer la salida del detector ni las clasificaciones de las demás personas expertas (clasificación ciega e independiente), reduciendo el riesgo de sesgo de anclaje.

Tipo	Descripción
Variable de agrupación (fuente de clasificación)	Dos niveles: (a) salida del detector automático, (b) consenso de personas expertas. No es una variable manipulada experimentalmente; el diseño es observacional-comparativo (<i>diagnostic accuracy study</i>).
Variable dependiente primaria	Clasificación binaria de cada RF: <i>ambiguo</i> / <i>no ambiguo</i> , emitida por cada fuente.
Variables dependientes derivadas	Precisión, exhaustividad (<i>recall</i>), medida F1 del detector respecto al consenso experto; κ de Cohen por par de expertos; κ de Fleiss para el conjunto de expertos.
Variables de control	(i) mismo conjunto congelado de 25 RF, en la redacción vigente al momento de la clasificación; (ii) expertos ciegos entre sí y ciegos a la salida del detector; (iii) mismo momento de aplicación para todas las personas evaluadoras (o ventana temporal acotada); (iv) misma definición operativa de “ambigüedad” entregada a todas las partes (Sección 7.2 de este protocolo).
Variables extrañas reconocidas	Experiencia previa de cada persona experta en redacción de requisitos; posible familiaridad previa con el dominio cárnico. Se documentan en la ficha de perfil del experto (Sección 7.3) y se discuten como amenaza a la validez en la Sección 11.

Table 3: Variables del estudio.

Orden de aplicación. Los RF se presentan a cada persona experta en un orden aleatorizado con semilla fija $\text{seed} = 42$ por evaluador (una permutación distinta y reproducible por persona, generada con `random.Random(42 + índice_evaluador)` en Python), para controlar efectos de fatiga o de posición serial sin perder la trazabilidad del orden exacto mostrado a cada persona.

7 Población, muestra y criterios de selección

Población de requisitos. Los 25 RF del ERS/SRS v3.0 (Sección 3.2), incluyendo RF-17 a RF-25 de la segunda ronda. **Precondición de ejecución:** dado que el ERS marca las evidencias EV-17 a EV-25 como pendientes de consolidación, el conjunto de 25 RF solo se congela para clasificación una vez que dichas evidencias estén respaldadas por evidencia real de campo, conforme a la advertencia global de la guía sobre generación de texto sin evidencia empírica. El equipo verifica y deja constancia de este cierre en `06_Experimento/resultados/` antes del paso 2 del procedimiento (Sección 8).

Personas expertas evaluadoras. Mínimo 3, recomendado 5 (Sección 5.1 de la guía de la Entrega 3). Criterios de inclusión propuestos:

- Formación o experiencia en ingeniería de requisitos o ingeniería de software (estudiante avanzado, docente o profesional).
- No pertenecer al equipo CarniCore (para evitar conflicto de interés y sesgo de autor).
- Disponibilidad para completar la clasificación de los 25 RF de forma individual e independiente dentro de la ventana de aplicación definida.

Las identidades y roles concretos de las personas expertas reclutadas (por ejemplo, estudiantes de otro paralelo o docentes del área) se registran, bajo código de participante y no bajo nombre,

en `06_Experimento/instrumentos/ficha_perfil_experto.csv` una vez confirmado el panel completo.

Tamaño muestral. No aplica cálculo de potencia sobre el número de RF, dado que se trabaja con el censo completo (25 RF) y no con una muestra probabilística. El número de personas expertas (mínimo 3) sigue el mínimo metodológico usual para el cálculo de κ de Fleiss con más de dos evaluadores [4].

8 Instrumentos

8.1 Detector automático de ambigüedad y malos olores

El detector clasifica cada RF como *ambiguo* o *no ambiguo* a partir de patrones textuales conocidos en la literatura [2, 3]:

- **Cuantificadores vagos:** adjetivos o adverbios sin umbral verificable (por ejemplo, “rápido”, “adecuado”, “suficiente”, “fácil”) no acompañados de una métrica.
- **Conjunciones múltiples:** uso de “y”/“o” que agrupa dos o más obligaciones distintas dentro de un mismo RF, dificultando su verificación individual.
- **Voz pasiva sin agente explícito:** construcciones que ocultan quién o qué componente del sistema ejecuta la acción.

El equipo adopta un script propio en Python (expresiones regulares por categoría), con su respectivo listado de patrones versionado en `06_Experimento/scripts_analisis/detector_ambigüedad.py`, congelado en la versión 1.0 antes de ejecutar el experimento; la herramienta *smella* de Ferrari et al. queda documentada como alternativa no adoptada por razones de compatibilidad con el español. Como en la implementación inicial de las expresiones regulares se utilizó un modelo de lenguaje como apoyo técnico de prototipado, dicho uso se documenta íntegramente en `06_Experimento/prompts_llm/` con el *prompt* exacto, modelo, temperatura, *top-p* y semilla, conforme a la Sección 4 de la Adenda Ética de la Segunda Ronda: el modelo no participa en ningún caso en la clasificación experta.

8.2 Rúbrica de clasificación experta

Instrumento binario aplicado por cada persona experta a cada uno de los 25 RF, de forma individual e independiente:

Se incluye al inicio del instrumento una definición operativa única de “ambigüedad” (RF que admite más de una interpretación razonable sobre qué debe hacer el sistema, sobre qué componente lo ejecuta, o sobre cómo verificar su cumplimiento), idéntica para las tres o más personas expertas, para minimizar la varianza de criterio.

8.3 Ficha de perfil de la persona experta

Registra, sin datos identificables más allá de un código de participante (EXP-01, EXP-02, ...): años de experiencia o formación en ingeniería de requisitos, rol actual (docente / estudiante avanzado / profesional), y vínculo institucional. Se archiva en `06_Experimento/instrumentos/`.

Campo	Instrucción
Identificador del RF	Copiado literalmente del ERS (RF-01 a RF-25), sin el atributo de prioridad ni de fuente, para no inducir sesgo.
Clasificación	<i>Ambiguo</i> / <i>No ambiguo</i> (obligatorio, opción única).
Categoría de ambigüedad (si aplica)	Cuantificador vago / Conjunción múltiple / Voz pasiva sin agente / Otra (especificar en texto libre, máximo una línea).
Nivel de confianza	Escala Likert 1–5 sobre la seguridad de la propia clasificación.

Table 4: Estructura de la rúbrica de clasificación experta.

8.4 Consentimiento informado de personas expertas

Se adapta el formato de consentimiento informado ya aprobado en el paquete ético (08_Etica/A03_Consentimiento_Informado.pdf) para el rol específico de *persona evaluadora experta*, incorporando la cláusula de uso de la clasificación emitida (no de datos personales sensibles) en publicaciones científicas revisadas por pares y en el conjunto de datos anónimo depositado en Zenodo, conforme a la Sección 5 de la Adenda Ética de la Segunda Ronda. La versión adaptada, distinta del consentimiento de participantes de campo, se anexa como 06_Experimento/instrumentos/consentimiento_experto_v1.0.pdf.

9 Procedimiento

El procedimiento sigue, sin alteraciones, los seis pasos descritos para el Enfoque 2 en la Sección 5.2 de la guía de la Entrega 3 (2A):

1. **Selección del detector:** elegir y congelar la versión de la herramienta o del script (Sección 7.1 de este protocolo).
2. **Ejecución del detector** sobre el conjunto completo de 25 RF del ERS, clasificando cada uno como “ambiguo” o “no ambiguo”, con registro del resultado crudo en 06_Experimento/resultados/.
3. **Clasificación experta:** entregar los 25 RF (sin el resultado del detector) a un mínimo de tres personas expertas, que clasifican de forma independiente siguiendo la rúbrica de la Sección 7.2.
4. **Cálculo de precisión, *recall* y F1** del detector, tomando como referencia el consenso experto (mayoría simple entre las personas evaluadoras; en caso de empate, se registra como desacuerdo no resuelto y se documenta aparte).
5. **Cálculo del acuerdo inter-evaluador:** κ de Cohen [1] para cada par de expertos y κ de Fleiss [4] para el conjunto completo.
6. **Discusión de desacuerdos:** para cada RF donde el detector y el consenso experto difieren, redactar una nota breve que explique la posible razón del desacuerdo y qué aprende el equipo de ese caso.

Todos los artefactos intermedios (salida cruda del detector, rúbricas completadas, cálculos de métricas) se versionan en `06_Experimento/resultados/` y `06_Experimento/scripts_analisis/`, de modo que el análisis sea reproducible a partir de los datos crudos, conforme a la Sección 7.6 de la guía de la Entrega 3 (2A).

10 Plan de análisis estadístico

1. **Estadística descriptiva:** distribución de clasificaciones (ambiguo / no ambiguo) por el detector y por cada persona experta; matriz de confusión del detector frente al consenso experto.
2. **Métricas de exactitud diagnóstica:** precisión, exhaustividad (*recall*) y medida F1, con intervalos de confianza aproximados dado el tamaño reducido de la población (25 RF).
3. **Acuerdo inter-evaluador:** κ de Cohen por par de expertos [1]; κ de Fleiss para el conjunto [4]; interpretación cualitativa del nivel de acuerdo (pobre, moderado, sustancial, casi perfecto).
4. **Prueba de hipótesis sobre el acuerdo detector-consenso:** dado que la variable es categórica binaria pareada sobre una población censal pequeña, no se aplica la prueba de normalidad de Shapiro-Wilk (reservada para variables continuas); en su lugar, se evalúa si κ es significativamente distinto de cero mediante el error estándar asintótico de κ de Cohen, fijando $\alpha = 0,05$. Si en una versión posterior del estudio se incorporan puntuaciones continuas (por ejemplo, nivel de confianza), se aplicará Shapiro-Wilk antes de elegir entre pruebas paramétricas y no paramétricas, conforme a la Sección 5 de la guía de la Entrega 3 (2A).
5. **Corrección por comparaciones múltiples:** si se calculan múltiples κ pareados (uno por cada par de expertos) y se reporta cada uno con su propia prueba de significancia, se aplica corrección de Bonferroni sobre el conjunto de comparaciones pareadas.
6. **Software:** el análisis se implementa en Python (`scikit-learn` para precisión, *recall* y F1; `statsmodels.stats.inter_rater` para κ de Cohen y de Fleiss), en `06_Experimento/scripts_analisis/analisis_kappa_f1.py`, con las versiones exactas de las librerías congeladas en un archivo `requirements.txt` versionado en la misma carpeta, conforme a la Sección 8.7 de la guía de la Entrega 3 (2A).

11 Consideraciones éticas

Este protocolo opera bajo el paquete ético ya aprobado para CarniCore en `08_Etica/` (categoría de riesgo C – riesgo mínimo operativo), y en particular bajo los límites declarados en la Sección 4 de la Adenda Ética de la Segunda Ronda (`08_Etica/Adenda_Segunda_Ronda.pdf`) sobre el uso de asistentes de inteligencia artificial: cualquier apoyo de un modelo de lenguaje se limita a tareas técnicas de prototipado del detector, nunca a la clasificación experta ni a la generación de hallazgos.

Las personas expertas evaluadoras participan mediante consentimiento informado específico (Sección 7.4 de este protocolo), que autoriza explícitamente el uso de su clasificación anónima en publicaciones científicas revisadas por pares y en el conjunto de datos depositado en Zenodo bajo licencia CC BY 4.0, conforme a la Sección 5 de la Adenda Ética de la Segunda Ronda. No se recolecta ningún dato personal identificable de las personas expertas más allá de un código de participante.

Precondición de ejecución: el ejemplar de la Adenda Ética de la Segunda Ronda disponible en el repositorio al momento de escribir este protocolo registra el visto bueno docente como “Pendiente” y los campos de número de participantes previstos por rol en blanco. Este protocolo exige que dicha adenda esté firmada y con las cifras completas **antes** de recabar el primer consentimiento de persona experta, conforme al gatekeeper G8 de la guía de la Entrega 3 (2A); el equipo deja constancia del cierre de la adenda en el cronograma (Sección 12, semana 11) antes de iniciar el reclutamiento.

12 Amenazas a la validez (avance)

Se adelanta un análisis preliminar siguiendo la clasificación de Wohlin et al. [7]; el análisis completo, sustentado en los datos ya recogidos, se cierra en la Entrega 4 (2B).

- **Validez de constructo:** la definición operativa de “ambigüedad” entregada a las personas expertas puede no capturar exactamente el mismo constructo que las categorías de patrones textuales programadas en el detector. Mitigación: definición única y explícita compartida por ambas fuentes (Sección 7.2).
- **Validez interna:** el orden de presentación de los RF a cada experto podría introducir efectos de fatiga o de aprendizaje. Mitigación: aleatorización del orden por evaluador.
- **Validez externa:** el conjunto de 25 RF pertenece a un único sistema y dominio (distribución cárnica ecuatoriana); los resultados no se generalizan automáticamente a otros dominios o a conjuntos de mayor tamaño.
- **Validez de conclusión:** el tamaño reducido de la población (25 RF) limita la potencia estadística de las pruebas de significancia sobre κ ; se prioriza el reporte del tamaño del efecto sobre el valor p aislado.

13 Cronograma de ejecución

Semana	Actividad
11	Cierre de la Adenda Ética de la Segunda Ronda con el enfoque empírico declarado; registro de este protocolo en OSF completado el 02/08/2026 (https://osf.io/wud69), con fecha anterior a la ejecución del experimento. Comprobante en 06_Experimento/osf_registration.pdf.
12	Congelamiento del conjunto de 25 RF; selección y versionado del detector; reclutamiento y consentimiento de las personas expertas; ejecución del detector y de la clasificación experta ciega.
13	Cálculo de métricas y de acuerdo inter-evaluador; redacción de la nota de desacuerdos; consolidación de 06_Experimento/resultados/ y 06_Experimento/scripts_analisis/; entrega 2A.
14–15	Análisis complementario, figuras y tablas finales; incorporación al manuscrito paralelo (Secciones de Resultados y Discusión).

Table 5: Cronograma de ejecución del componente empírico, alineado con el cronograma general de la Sección 10 de la guía de la Entrega 3 (2A) y con la Sección A.2 del ERS/SRS.

Referencias

References

- [1] Jacob Cohen. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46, 1960.
- [2] Alessio Ferrari, Paola Spoletini, and Stefania Gnesi. Ambiguity and tacit knowledge in requirements elicitation interviews. *Requirements Engineering*, 21(3):333–355, 2016.
- [3] Jannik Fischbach, Julian Frattini, Andreas Vogelsang, Daniel Mendez, Michael Unterkalmsteiner, Anke Wehrle, Parisa Rezaei Henao, Parisa Yousefi, Tedi Juricic, Jeremias Radduenz, and Christoph Wiecher. Automatic creation of acceptance tests by deriving conditionals from natural language requirements. *Information and Software Technology*, 154:107055, 2023.
- [4] Joseph L. Fleiss. Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5):378–382, 1971.
- [5] Andreas Jedlitschka, Marcus Ciolkowski, and Dietmar Pfahl. Reporting experiments in software engineering. In Forrest Shull, Janice Singer, and Dag I. K. Sjøberg, editors, *Guide to Advanced Empirical Software Engineering*, pages 201–228. Springer London, London, 2008.
- [6] Brian A. Nosek, Charles R. Ebersole, Alexander C. DeHaven, and David T. Mellor. The preregistration revolution. Technical Report 11, Proceedings of the National Academy of Sciences, 2018.
- [7] Claes Wohlin, Per Runeson, Martin Höst, Magnus C. Ohlsson, Björn Regnell, and Anders Wesslén. *Experimentation in Software Engineering*. Springer, Berlin, Heidelberg, 2012.