

Detección automática de patrones de ambigüedad en requisitos funcionales: un estudio exploratorio en el dominio de trazabilidad cárnica

Castro Bajaña, A. O. Crespo Espinoza, K. O. Gamarra Araujo, E. X.
Pérez Ruiz, C. A. Quintero Gende, E. J.

Borrador – 02 de agosto de 2026 – No enviado a ninguna revista

Estado de este documento. Borrador de manuscrito, no enviado a ninguna revista. Reporta únicamente los resultados que existen como evidencia primaria real a la fecha: la salida de un detector automático de patrones aplicado sobre los 25 requisitos funcionales (RF) del sistema CarniCore. El estudio **no incluye** comparación con un panel de personas expertas: el equipo no contó con acceso a evaluadores externos independientes durante esta entrega, por lo que esa validación se deja explícitamente fuera de alcance (Sección 7) en lugar de simularse o estimarse.

Abstract

Contexto. La ambigüedad textual en los requisitos de software es una causa documentada de retrabajo y de malentendidos entre partes interesadas. **Objetivo.** Caracterizar la presencia de patrones léxico-sintácticos de ambigüedad – cuantificadores vagos, conjunciones múltiples y voz pasiva sin agente explícito – en el conjunto completo de requisitos funcionales de CarniCore, un sistema real en desarrollo para la gestión de trazabilidad, pesaje inteligente e inventario de una distribuidora de productos cárnicos en Ecuador. **Método.** Se implementó un detector basado en expresiones regulares con tres categorías de patrón y se ejecutó sobre los 25 RF verbatim del ERS/SRS v3.0 (población completa, sin muestreo). **Resultados.** El detector no activó ninguna de las tres categorías en ninguno de los 25 RF (0/25, 0%). **Conclusiones.** El hallazgo es consistente con un estilo de redacción disciplinado y homogéneo en el corpus analizado, pero no permite concluir ausencia de ambigüedad en sentido amplio: los patrones detectados son únicamente léxico-sintácticos y no capturan la ambigüedad semántica o pragmática (p. ej., umbrales temporales no especificados), cuya identificación requiere juicio humano y queda como trabajo futuro no ejecutado en este estudio por falta de acceso a un panel de personas evaluadoras.

1 Introducción

La calidad de los requisitos de software condiciona directamente el éxito de un proyecto: la ambigüedad textual en un requisito – la posibilidad de que admita más de una interpretación razonable – es una de las causas más documentadas de retrabajo, defectos y malentendidos entre partes interesadas en Ingeniería de Requisitos (Femmer et al., 2017; Ferrari y Esuli, 2019). Detectar esta ambigüedad de forma temprana, idealmente de manera automatizada, es un objetivo práctico de larga data en el área.

Este artículo presenta un estudio exploratorio que aplica un detector automático de ambigüedad basado en patrones textuales (cuantificadores vagos, conjunciones múltiples y voz pasiva sin agente explícito) sobre el conjunto completo de 25 requisitos funcionales de CarniCore, un sistema real en desarrollo. A diferencia de un diseño comparativo clásico de detección de ambigüedad, este estudio no contrasta la salida del detector contra el juicio de personas expertas: esa

comparación quedó fuera de alcance por falta de acceso a un panel de evaluadores independientes durante el periodo de esta entrega, y se documenta como trabajo futuro (Sección 7).

Contribuciones

- Un detector de ambigüedad de código abierto, reproducible, con tres categorías de patrón documentadas (`detector_ambigüedad.py`).
- Una caracterización empírica real – no simulada – de la presencia de estos patrones en el conjunto completo de RF de un sistema en producción temprana.
- Un conjunto de datos abierto (Zenodo, licencia CC BY 4.0) con la salida del detector sobre los 25 RF.
- Una discusión explícita de las limitaciones de un detector puramente léxico frente a la ambigüedad semántica, que motiva un diseño de validación con panel experto para trabajo futuro.

2 Trabajo relacionado

La detección automática de ambigüedad y de “malos olores” (*smells*) en requisitos en lenguaje natural ha sido estudiada mediante enfoques basados en reglas y expresiones regulares (Femmer et al., 2017), en procesamiento de lenguaje natural clásico (Ferrari y Esuli, 2019; Chantree et al., 2006) y, más recientemente, en modelos de lenguaje de gran escala aplicados en contextos industriales (Bashir et al., 2025). Gervasi et al. (2019) proponen un marco unificador para distinguir tipos de ambigüedad (léxica, sintáctica, semántica, pragmática), marco que se retoma en la Sección 6 para interpretar los límites de este estudio. Philippo et al. (2013) reportan que la ambigüedad percibida por personas evaluadoras no siempre coincide con la ambigüedad detectada formalmente – un hallazgo directamente relevante para justificar por qué el detector aquí usado, al ser puramente léxico, no agota la noción de ambigüedad de un requisito.

A diferencia de estudios que contrastan un detector contra el consenso de un panel experto (diseño que este equipo pre-registró en OSF para una fase posterior, <https://osf.io/wud69>), este estudio se limita a la caracterización descriptiva del detector sobre un conjunto de requisitos originales, elicitados de campo por el propio equipo para un sistema real – lo que introduce validez externa distinta (dominio no explorado previamente en la literatura de ambigüedad de requisitos: trazabilidad de productos cárnicos en un contexto latinoamericano) a costa de no contar con una referencia de juicio humano en esta entrega.

3 Diseño del estudio

Pregunta de investigación. ¿En qué medida los requisitos funcionales de CarniCore presentan los patrones léxico-sintácticos de ambigüedad descritos en la literatura de *requirements smells* (cuantificadores vagos, conjunciones múltiples, voz pasiva sin agente explícito)?

Diseño. Estudio observacional, descriptivo, transversal y censal: se analiza el 100 % de la población de 25 RF de CarniCore (RF-01 a RF-25), sin muestreo. No se plantea contraste de hipótesis inferencial en esta entrega, dado que no hay una segunda fuente de clasificación (panel experto) contra la cual comparar al detector; el diseño comparativo completo permanece pre-registrado en OSF para ejecución futura.

4 Método

4.1 Población

Los 25 RF completos del ERS/SRS v3.0 de CarniCore, citados de forma verbatim (Sección 3.2 del ERS/SRS), sin los atributos de identificador, fuente, prioridad ni estabilidad.

4.2 Detector automático

Script propio en Python (`06_Experimento/scripts_analisis/detector_ambigüedad.py`), con tres categorías de patrón:

- **Cuantificadores vagos:** adjetivos y adverbios sin criterio verificable (p.ej. “apropiado”, “suficiente”, “rápidamente”, “aproximadamente”).
- **Conjunciones múltiples:** más de tres conectores coordinantes (*y/o*) o más de dos verbos modales (*deberá*) dentro de un mismo RF, como señal de un requisito potencialmente compuesto.
- **Voz pasiva sin agente explícito:** construcciones pasivas perifrásticas o reflejas no seguidas de un complemento agente (*por + sujeto*).

Un RF se clasifica como `ambiguo_detector = 1` si activa al menos una categoría. La regla de decisión y el listado completo de patrones se fijaron antes de examinar los resultados y no se modificaron después.

5 Resultados

Se ejecutó el detector sobre los 25 RF. Ningún RF activó ninguna categoría:

Categoría de patrón	RF que la activaron
Cuantificador vago	0/25
Conjunción múltiple (>3 conectores ó >2 verbos modales)	0/25
Voz pasiva sin agente explícito	0/25
Al menos una categoría (<code>ambiguo_detector = 1</code>)	0/25 (0 %)

Este resultado es consistente con el estilo de redacción observado en el ERS: los 25 RF siguen sistemáticamente la plantilla “*El sistema deberá permitir/registrar/calcular + objeto directo concreto*”, en voz activa, sin los cuantificadores léxicos ni las estructuras pasivas que el detector busca. Es un resultado determinístico y reproducible: cualquier reejecución del script sobre el mismo texto produce idéntica salida.

6 Discusión

Un resultado de 0/25 en un detector puramente léxico **no equivale a afirmar que los 25 RF están libres de ambigüedad**. Siguiendo el marco de Gervasi et al. (2019), el detector aquí implementado cubre únicamente ambigüedad léxica y sintáctica superficial; no cubre ambigüedad semántica ni pragmática. Dos ejemplos del propio corpus ilustran el límite: RF-08 (“genera una alerta visual cuando *esté próximo a vencer*”) no especifica un umbral numérico explícito en su redacción principal – aunque el criterio de aceptación asociado sí lo fija en un documento separado del ERS –, y RF-21 (“sincronizándolas *automáticamente* al restablecerse la conectividad”) no describe el mecanismo de sincronización en la propia oración del requisito. Ninguno de los dos

activa un patrón léxico del detector, pero ambos podrían generar interpretaciones distintas en un lector sin acceso al resto del documento – precisamente el tipo de discrepancia que Philipppo et al. (2013) documentan entre ambigüedad formalmente detectada y ambigüedad percibida.

Esta discusión es preliminar y no puede resolverse sin la fase comparativa contra juicio humano, que este estudio no ejecutó. El equipo considera que el resultado 0/25 es en sí mismo informativo – sugiere que, si existe ambigüedad percibida en este corpus, es probable que sea de tipo semántico o pragmático y no léxico – pero se abstiene de cuantificar esa probabilidad sin datos de un panel experto.

7 Amenazas a la validez

- **Validez de constructo.** El detector solo opera sobre tres categorías léxico-sintácticas; un resultado de 0 positivos puede reflejar ausencia real de esos patrones o cobertura insuficiente del detector (p.ej., listas de cuantificadores vagos incompletas para el español técnico usado en este dominio).
- **Ausencia de validación externa.** No se comparó la salida del detector contra ningún juicio humano en esta entrega; no hay, por tanto, evidencia de precisión o *recall* del detector frente a la ambigüedad realmente percibida por lectores del ERS.
- **Tamaño y alcance.** 25 RF de un único sistema, elicitados por un único equipo, en un único dominio (trazabilidad cárnica) y en español de Ecuador; no se reclama generalización a otros corpus o idiomas.
- **Ausencia de revisión por pares.** Este es un borrador no enviado ni revisado.

8 Trabajo futuro

El equipo pre-registró en OSF (<https://osf.io/wud69>, 02/08/2026) un diseño comparativo completo – detector vs. consenso de un mínimo de tres personas expertas, con cálculo de precisión, *recall*, F1 y acuerdo inter-evaluador (κ de Cohen y de Fleiss) – que no se ejecutó en el periodo de esta entrega por falta de acceso a un panel de evaluadores independientes. Ese diseño permanece disponible en el protocolo experimental (06_Experimento/protocolo.pdf) para ejecución en una fase posterior del proyecto, en caso de contar con los recursos humanos necesarios.

Disponibilidad de datos

El conjunto de datos (salida real del detector sobre los 25 RF) se deposita en Zenodo bajo licencia Creative Commons Atribución 4.0 Internacional (CC BY 4.0), conforme a 07_Publicacion/dataset_zenodo/. El DOI se agrega tras el depósito.

Referencias (parciales, formato a normalizar antes del envío)

- Bashir, S., Ferrari, A., Khan, M. A., Strandberg, P. E., Haider, Z., Saadatmand, M., Bohlin, M. (2025). Requirements Ambiguity Detection and Explanation with LLMs: An Industrial Study. *ICSME 2025*.
- Chantree, F., Nuseibeh, B., De Roeck, A., Willis, A. (2006). Identifying Nocuous Ambiguities in Natural Language Requirements.
- Femmer, H., Méndez Fernández, D., Wagner, S., Eder, S. (2017). Rapid quality assurance with requirements smells. *Journal of Systems and Software*, 123, 190–213.
- Ferrari, A., Esuli, A. (2019). An NLP approach for cross-domain ambiguity detection in requirements engineering. *Automated Software Engineering*, 26(3), 559–598.

- Gervasi, V., Ferrari, A., Zowghi, D., Spoletini, P. (2019). Ambiguity in Requirements Engineering: Towards a Unifying Framework. *From Software Engineering to Formal Methods and Tools, and Back*. Springer.
- Philippo, E. J., Heijstek, W., Kruiswijk, B., Chaudron, M.R. V., Berry, D.M. (2013). Requirement Ambiguity Not as Important as Expected – Results of an Empirical Evaluation. *REFSQ Workshops*, 65–79.

Nota de cumplimiento. Todos los datos reportados en este manuscrito (Sección 5) son reales, producidos por ejecución efectiva de `detector_ambigüedad.py` sobre los 25 RF verbatim del ERS/SRS. No se reporta ninguna cifra de precisión, *recall*, F1 ni κ porque la fase comparativa con panel experto no se ejecutó en este periodo – se documenta como trabajo futuro (Sección 7) en lugar de estimarse o simularse, conforme a la advertencia de la Guía y Rúbrica de la Entrega 3 (2A) sobre fabricación de evidencia (gatekeeper G4).